UNIVERSIDAD POLITECNICA

Ingeniería en Tecnologías de la Información e Innovación Digital

Materia:

PROBABILIDAD

Docente:

Horacio Irán Solís Cisneros

Actividad:

Desarrollar una aplicación en Python con interfaz gráfica

2do cuatrimestre

2-C

Carlos Armando Cruz Castro_253385

Frank Edwin Carrasquedo Vázquez_253389

Valencia Diaz Jahaziel_253451

Sistema de Análisis Probabilístico con Teorema de Bayes

---

1. Introducción

El análisis probabilístico es una herramienta fundamental dentro del campo de la ingeniería en información y análisis de datos, ya que permite estudiar fenómenos que presentan incertidumbre y realizar predicciones basadas en información disponible. En distintos sistemas tecnológicos, como monitoreo industrial, mantenimiento predictivo y detección de anomalías, resulta importante estimar la probabilidad de que ocurra un evento anómalo a partir de diferentes variables observadas.

La aplicación de métodos estadísticos permite analizar la relación entre variables y determinar si ciertas condiciones aumentan o disminuyen la probabilidad de que ocurra un evento específico. A través del análisis de datos es posible identificar patrones que contribuyan a la toma de decisiones informadas.

Uno de los enfoques más utilizados para este tipo de análisis es el **Teorema de Bayes**, el cual permite actualizar la probabilidad de un evento a medida que se obtiene nueva evidencia. Este principio es ampliamente utilizado en áreas como inteligencia artificial, aprendizaje automático y análisis de datos.

En esta práctica se desarrolló una aplicación en Python utilizando **Streamlit**, la cual permite cargar archivos en formato CSV, analizar automáticamente las variables del dataset, calcular probabilidades condicionales y aplicar el Teorema de Bayes para analizar la probabilidad de fallas dentro de un sistema.

---

2. Marco Teórico

Definición de evento

En probabilidad, un evento es cualquier resultado o conjunto de resultados que puede ocurrir dentro de un experimento aleatorio. En el contexto de esta práctica, el evento analizado corresponde a la ocurrencia de una **falla en el sistema**, representada mediante una variable binaria.

Probabilidad clásica

La probabilidad clásica se define como la relación entre el número de casos favorables y el número total de resultados posibles.

$$P(A) = \frac{\text{Casos favorables}}{\text{Casos totales}}$$

Probabilidad condicional

La probabilidad condicional describe la probabilidad de que ocurra un evento A dado que ya ocurrió otro evento B.

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}$$

$$P(B)$$

$$P(A \cap B)$$

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)} \approx$$

Este concepto permite analizar cómo ciertas condiciones influyen en la ocurrencia de un evento.

Independencia de eventos

Dos eventos se consideran independientes cuando la ocurrencia de uno no afecta la probabilidad del otro.

El modelo **Naive Bayes** asume que las variables utilizadas para la predicción son independientes entre sí.

Teorema de Bayes

El Teorema de Bayes permite calcular la probabilidad de un evento considerando evidencia previa.

$$P(A \mid B) = \frac{P(B \mid A)P(A)}{P(B)}$$

$$P(A)$$

$$P(B \mid A)$$

$$P(B \mid \neg A)$$

$$P(A \mid B) = \frac{P(B \mid A)P(A)}{P(B)} \approx 0 \,,\; P(B) \approx 0$$

Este teorema permite actualizar probabilidades conforme se obtiene nueva información.

Variables aleatorias

Una variable aleatoria es una variable cuyo valor depende del resultado de un experimento aleatorio. Estas pueden ser discretas o continuas.

En el dataset utilizado se manejan variables numéricas como temperatura y presión.

---

3. Preparación del Dataset

El dataset utilizado en esta práctica se encuentra almacenado en un archivo con extensión **CSV** y contiene datos simulados relacionados con el comportamiento de un sistema monitoreado.

El conjunto de datos contiene **10 registros**, donde cada registro representa una observación del sistema.

Las variables del dataset son:

Variable	Tipo	Descripción
Temperatura	Numérica	Temperatura del sistema
Presión	Numérica	Presión del sistema
Falla	Binaria	Indica si ocurrió una falla

La variable **falla** representa el evento de interés dentro del análisis probabilístico.

Vista del dataset

Vista previa del dataset

	temperatura	presion	falla
0	30	101	0
1	35	100	0
2	40	99	1
3	45	98	1
4	50	97	1

Figura 1. Vista previa del dataset cargado en la aplicación.

En la Figura 1 se muestra la vista previa del dataset cargado dentro de la aplicación desarrollada en Streamlit. Esta tabla permite verificar que los datos fueron cargados correctamente desde el archivo CSV.

Detección de variables

```
Columnas numéricas:
[
  0 : "temperatura"
  1 : "presion"
  2 : "falla"
]
Columnas categóricas:
[]
Columnas de fecha:
[
  0 : "temperatura"
  1 : "presion"
  2 : "falla"
]
```

Figura 2. Detección automática de tipos de variables.

El sistema identifica automáticamente las columnas del dataset utilizando la librería **pandas**, clasificando las variables según su tipo de dato.

---

4. Metodología

La metodología utilizada para el desarrollo de la práctica se divide en varias etapas.

Limpieza de datos

Durante el procesamiento de los datos se revisan los tipos de variables y se manejan posibles valores faltantes dentro del dataset para evitar errores en el análisis.

Selección de umbrales

Para calcular probabilidades condicionales se utiliza como referencia el **promedio de cada variable numérica**, el cual funciona como un umbral para determinar evidencia dentro del análisis.

Por ejemplo:

Temperatura mayor al promedio de temperatura.

Cálculo de probabilidades

El sistema calcula diferentes probabilidades dentro del análisis:

- Probabilidad base del evento
- Probabilidad de evidencia
- Probabilidad de evidencia dado el evento
- Probabilidad del evento dado la evidencia usando Bayes

Implementación del clasificador

Se implementó un modelo de clasificación utilizando el algoritmo **Naive Bayes** mediante la librería **Scikit-Learn**.

El dataset se divide en:

- 70% para entrenamiento
- 30% para prueba

Posteriormente el modelo es entrenado y evaluado utilizando métricas de clasificación.

5. Resultados

Histogramas de variables

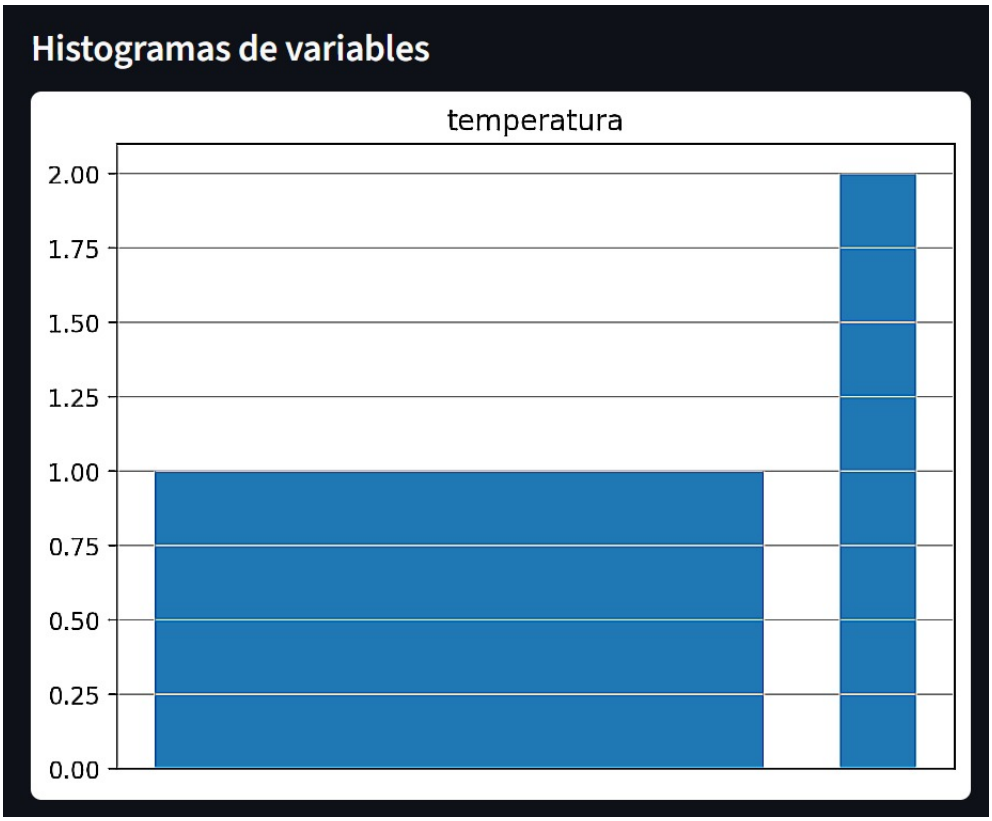

Figura 3. Histograma de la variable temperatura.

El histograma permite observar la distribución de los valores de temperatura dentro del dataset, mostrando cómo se distribuyen los datos en diferentes rangos.

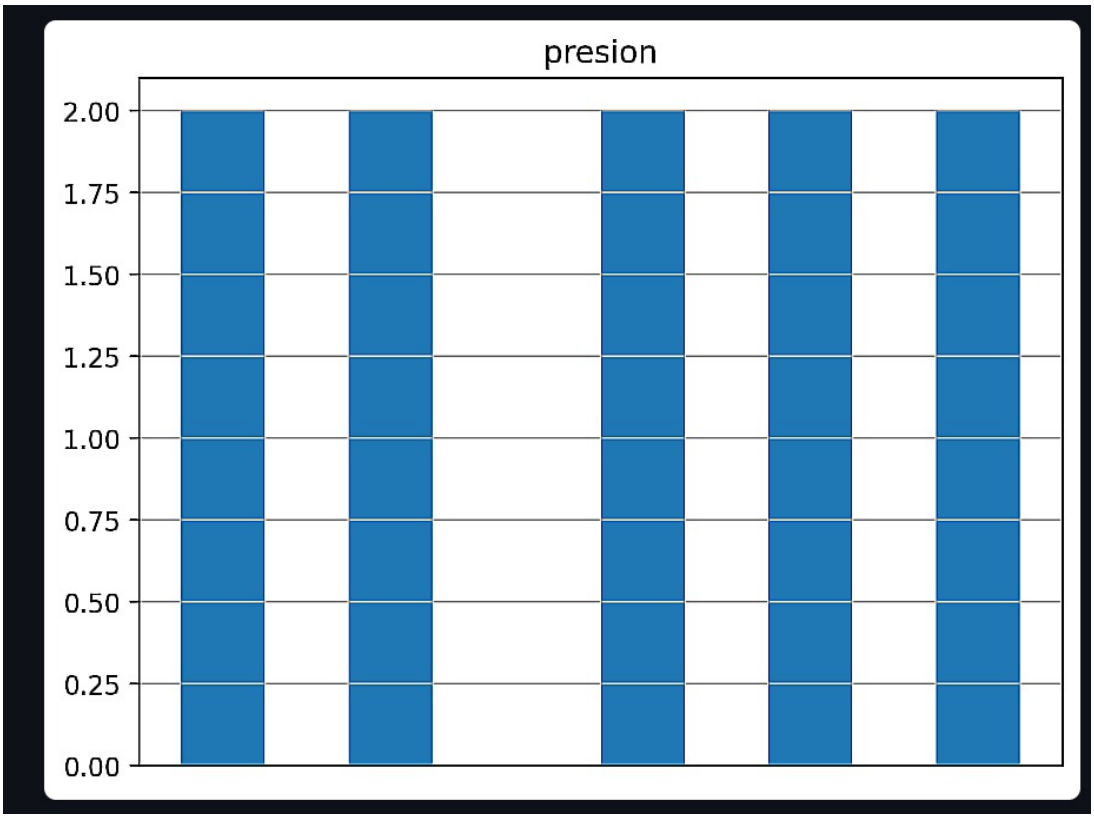

Figura 4. Histograma de la variable presión.

Esta gráfica muestra la distribución de los valores de presión registrados en el sistema, permitiendo analizar la frecuencia de los distintos valores.

Gráfica temporal

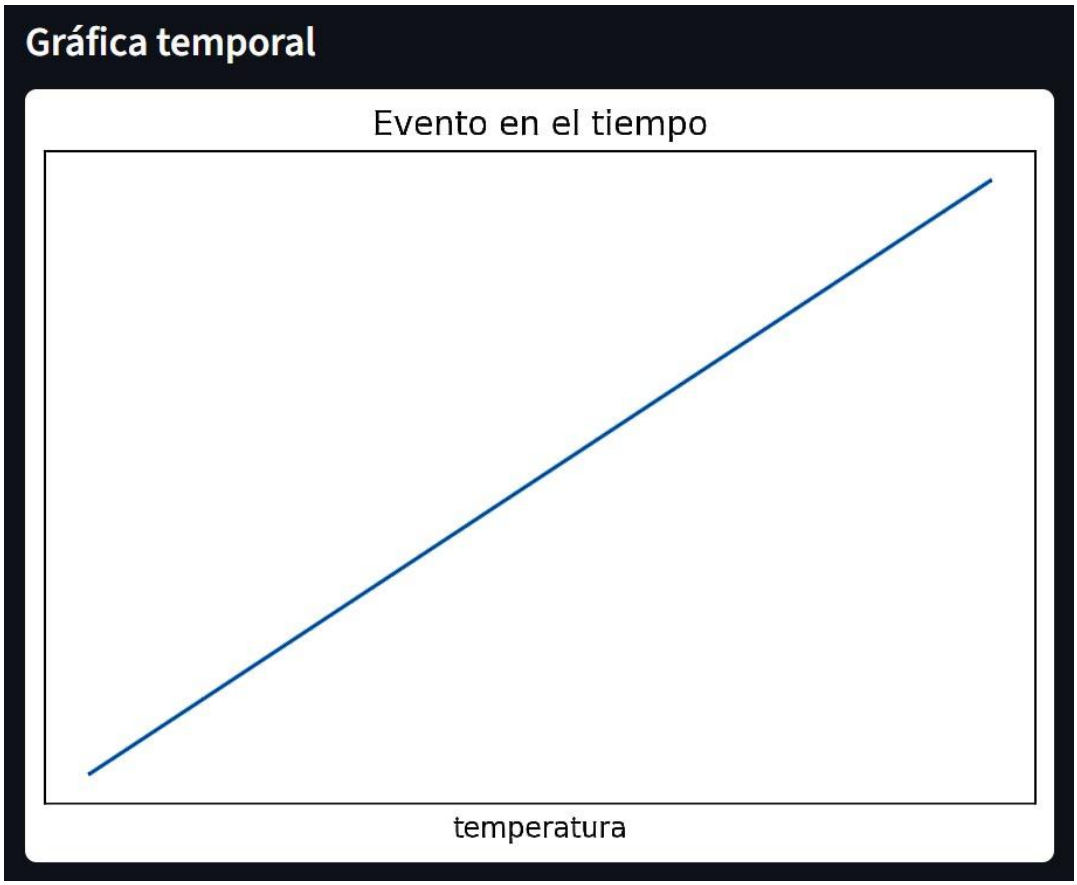

Figura 5. Gráfica temporal del evento.

La gráfica temporal permite observar el comportamiento del evento a lo largo de los registros disponibles dentro del dataset.

Distribución de la variable objetivo

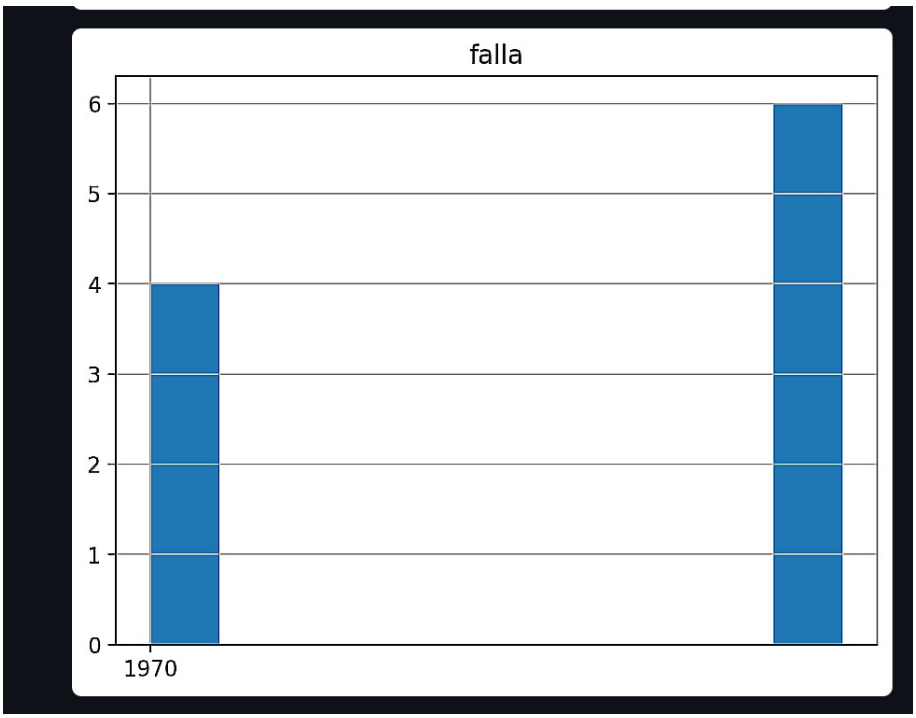

Figura 6. Distribución de la variable falla.

Esta gráfica muestra la frecuencia con la que ocurre el evento de falla dentro del dataset.

---

6. Análisis e Insights

A partir del análisis realizado se pueden obtener diversas observaciones.

La variable **temperatura** parece tener mayor influencia en la ocurrencia de fallas, ya que los registros con valores más altos coinciden frecuentemente con la presencia del evento.

El evento de falla ocurre en aproximadamente el **60% de los registros**, lo que indica que no se trata de un evento raro dentro del dataset.

Aunque el modelo Naive Bayes asume independencia entre variables, en sistemas reales variables como temperatura y presión pueden estar relacionadas entre sí.

Debido al tamaño reducido del dataset, los resultados obtenidos deben interpretarse con cautela, ya que un conjunto de datos pequeño puede afectar la precisión del modelo.

7. Conclusiones

El desarrollo de esta práctica permitió aplicar conceptos fundamentales de probabilidad y estadística mediante el uso de herramientas de análisis de datos en Python.

La aplicación desarrollada permite cargar datasets en formato CSV, analizar automáticamente las variables presentes y calcular probabilidades utilizando el Teorema de Bayes.

Además, se implementó un modelo de clasificación basado en **Naive Bayes**, el cual permite realizar predicciones sobre la ocurrencia de fallas a partir de variables observadas.

Entre las principales limitaciones del proyecto se encuentra el tamaño reducido del dataset utilizado. Como trabajo futuro se recomienda utilizar conjuntos de datos más grandes para mejorar la precisión del modelo y explorar otros algoritmos de aprendizaje automático.

En general, esta práctica permitió relacionar los conceptos teóricos estudiados en clase con una implementación práctica orientada al análisis probabilístico y la toma de decisiones basada en datos.